

# 시각장애인을 위한 이상 점자블록 탐지 및 경고 임베디드 시스템 개발 (A Development of the Anomaly Braille Block Detecting and Warning Embedded System for the Blind)

CUAI 5기 CV T4 Blueberry팀

김벼리(융합공학부), 김진우(기계공학부), 박도영(기계공학부), 서준혁(경영학부)

**[요약]** 본 연구는 점자블록의 파손, 훼손 및 이물질로 발생하는 시각장애인의 보행 위험 문제를 AI와 임베디드를 통해서 해결해보고자 했다. 구현한 오토인코더 모델은 AUC 94%, F1 Score 0.99의 성능을 보여주었으며, 실생활 적용 가능성 확보를 위해 라즈베리 파이와 연동하여 실시간으로 위험한 점자블록을 탐지하여 경고음을 내는 시스템을 개발하였다.

## 1. 서 론

인도, 지하철 타러 가는 길 등등 우리의 일상생활 속에서 마주하는 길에서 흔히 점자블록을 볼 수 있다. 점자블록은 점형블록, 선형블록으로 이루어져 있으며 이는 시각 장애인에게 위험한 지점과 보행 방향, 방향 전환에 대한 정보를 알려주는 중요한 보조 시설물이다.[1] 즉, 이 점자블록은 시각장애인들이 안전하게 다닐 수 있도록 길을 안내해주는 역할을 한다.

그러나 이런 점자블록 위에 전봇대가 세워져 있거나 점자블록이 횡단보도가 아닌 도로 중간으로 향해 있는 등, 여러 경우들로 인해서 오히려 시각장애인들을 위험으로 빠뜨릴 수 있다는 지적이 나온다.[2] 실제로 2018 ~ 2020년 기준으로 국민권익위에서 수집한 점자블록에 대한 민원은 총 2,847건이며, 이는 이전의 3년에 비해서 1.7배 많은 수치이다.[2] 이 조사 결과에 따르면 민원 유형 중 가장 많이 차지하고 있는 것은 점자블록 파손, 훼손에 의한 것이다.

이에 우리는 시각장애인들이 안전하게 보행을 할 수 있는 방안에서 가장 많이 민원이 들어오는 파손, 훼손에 의한 점자블록 문제에 주목하고, 이를 해결하는 방안으로 이상 점자블록을 탐지하는 딥러닝 모델을 만들고자 했다. 추가적으로 점자블록 상의 이물질도 보행에 위험이 된다고 생각되어 함께 검출하도록 하였다. 실제 길거리의 점자블록을 촬영하여

데이터 수집을 진행하였고, 오토인코더를 사용한 모델을 만들었다. 또한, 실생활 적용 가능성에 대해서도 확보하고자 했다. 라즈베리 파이의 경우, 실시간으로 데이터를 받아와서 결과를 출력해줄 수 있으며, 사이즈도 작고, AI모델을 임베디드에 적용하기 적합하다는 특징이 있다. 이런 특징이 실제 문제 상황과 유사한 환경에서 적용해보기에 적합하다고 생각하여 라즈베리 파이에 모델을 연동하였고, 실제 길거리를 다니면서 파손, 훼손 또는 위험한 점자블록을 탐지하여 경고음을 통해 알려줄 수 있도록 구현하였다.

## 2. 본 론

### 1) 데이터 수집 및 전처리

모델 학습에 필요한 점자블록 이미지를 확보하기 위해 서울 및 김해 일대의 점자블록을 촬영하였다. 송실대입구역 ~ 동작역, 강남역 ~ 뽕뽕사거리, 가산디지털단지, 대치역 ~ 은마사거리, 김해시 장유동 울하3로 일대에서 수집을 진행하여 다양한 환경에서의 점자블록 사진을 수집하였다. 모델 학습에서 점자블록의 이상 여부를 잘 분류할 수 있도록 카메라를 확대하여 점자블록 이미지를 수집하였다.



그림1. 수집한 점자블록 이미지(좌2\_정상, 우2\_이상점자블록)

정상 점자블록 이미지들은 회전, 수평 및 수직 평행이동, 상하좌우 대칭 등을 랜덤으로 부여하여 총 9774개의 이미지로 증강하였으며, 이상 점자블록은

29개의 이미지를 확보하였다.




그림2. 정상 점자블록 augmentation 결과

확보된 이미지들을 224\*224해상도로 조정하고 각 이미지에서 중앙의 128\*128 크기만큼 crop하여 전처리를 하였다. 9774개의 정상 데이터들을 9:1의 비율로 나눠 8796개의 정상 이미지로만 학습 데이터를 구성하였으며, 978개의 정상 이미지와 29개의 비정상 이미지를 합하여 총 1007개의 평가 데이터를 구성하였다. 정상 데이터를 0, 이상치를 1로 하여 평가 데이터에 대한 라벨 데이터셋(true class)을 구성하였다.

## 2) 모델 구조 및 bottleneck 결정

프로젝트는 정상 데이터와 비정상데이터를 구별해야 하는 이상치 탐지 문제에 해당하기 때문에 이상치 탐지에 많이 활용하는 오토인코더 모델을 선정하였다.

오토인코더는 입력 데이터를 받아 인코더 과정을 거쳐 bottleneck이라 불리는 code 계층의 latent space로 보내 중요한 핵심 정보만을 추리고, 이를 디코더의 입력으로 하여 입력 데이터를 재구성하는 비지도학습 신경망 모델이다[3]. 입력 데이터와 재구성된 데이터의 차이 정도에 따라 정상 데이터와 비정상 데이터를 구분하는 것이 오토인코더를 활용한 이상치 탐지이다.

오토인코더의 code 계층의 크기에 따라 복원하는 성능이 달라지기 때문에 이를 4, 8, 16으로 달리한 비교 모델을 구성하였다. 적층 컨볼루션 오토인코더 모델을 형성하였고, 데이터 전처리 후 얻은 데이터셋을 통해 batch size는 16, epoch는 100으로 설정하여 실험하였다.

표1. Code 파라미터에 따른 Autoencoder의 성능 비교

Code	Accuracy	Precision	Recall	F1Score
4	0.9309	0.9103	0.9416	0.9256
8	0.9433	0.9168	0.9381	0.9273
16	0.9549	0.9361	0.9484	0.9422

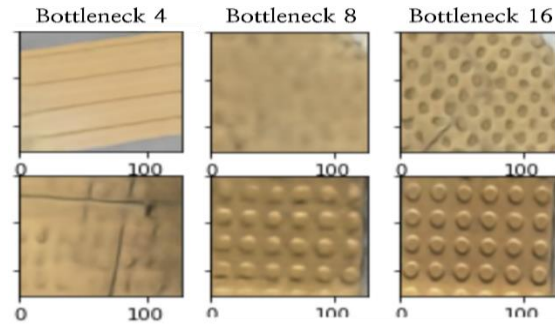


그림3. Autoencoder를 통한 이미지 복원 결과

3가지 모델 모두 90% 이상의 지표들을 출력하는 것을 확인할 수 있었다. 이미지 복원 결과와 함께 종합적으로 판단하였을 때, bottleneck이 16일때 가장 좋은 성능을 보여 모델 구조에 적용하였다.

## 3) 다양한 오토인코더를 이용하여 성능 비교

앞서 결정한 모델 구조를 기본으로 하여 오토인코더와 디노이징, 인페인팅 오토인코더 모델과의 성능을 비교하였다. 디노이징 오토인코더는 입력 이미지에 가우시안 분포 형태의 노이즈를 랜덤으로 씌우고, 인페인팅 오토인코더는 입력 이미지의 일부분을 랜덤으로 손상시켜 인코더에 입력하고 재구성하는 모델이다. Batch size는 16, epoch는 100, Loss는 mse로 설정하여 모델에 따른 성능을 비교하였다.

표2. 모델에 따른 Autoencoder의 성능 비교

Model	Accuracy	Val-Loss
Normal	0.9473	0.043
Denoising	0.9446	0.046
inpainting	0.9445	0.042

세 모델 모두 94% 이상의 Accuracy와 Val-loss를 보였다. 최종적으로 라즈베리 파이에서 구현하며, 실시간으로 영상을 입력 받기 때문에 이미지 전처리과정이 타 오토인코더에 비해 간단하여 메모리 사용량이 적으면서도 우수한 결과를 얻을 수 있는 일반 오토인코더 모델을 최종 모델로 선정하였다. Earlystopping을 활용해서 과적합되기 전 학습을 종료한 결과 179epoch에서 다음과 같은 성능의 모델을 얻었다.

표3. 최종 모델의 성능지표

Accuracy	Loss	Val-Accuracy	Val-Loss
0.9452	0.0037	0.9547	0.0044

## 4) Threshold 구하는 방법 결정

입력 이미지와 재구성된 이미지 차이의 정도를 비교해 비정상 이미지를 판별할 수 있기 때문에 recall과 precision을 모두 고려하여 threshold를 정하는 것이 중요하다. 이상치 판별 기준에 따른 모델 성능 차이 연구 논문[4]을 참고하여 범위, 최댓값, 누적 합, 평균의 4가지 통계치를 기준으로 삼아 최적의 threshold를 결정하였다. 본 모델은 각 통계치 별로 학습 데이터에 대한 분위수 0.985, 0.99, 0.995, 0.999에 해당하는 threshold를 선정하였고, 모델 성능 평가 지표로 F1 score, Accuracy, AUC를 선정하여 비교하였다.

표4에서 통계치의 AUC의 경우 범위를 이상치 판별 기준으로 하였을 때 94.02%의 가장 높은 성능을 보였고, 최댓값, 누적 합, 평균 순으로 낮았다. 분위수의 경우 각 통계치 별로 순위가 상이하게 나타났다.

표4. 통계치와 분위수에 따른 모델 성능 비교

Statistics	quantile	F1Score	Accuracy	AUC
범위	0.985	0.9893	0.9791	0.9402
	0.99	0.9903	0.9811	
	0.995	0.9893	0.9791	
	0.999	0.9879	0.9762	
최댓값	0.985	0.9873	0.9752	0.9300
	0.99	0.9857	0.9722	
	0.995	0.9878	0.9762	
	0.999	0.7584	0.6216	
누적 합	0.985	0.9852	0.9712	0.8651
	0.99	0.9868	0.9741	
	0.995	0.9858	0.9722	
	0.999	0.9859	0.9722	
평균	0.985	0.9827	0.9662	0.6115
	0.99	0.9868	0.9742	
	0.995	0.9874	0.9752	
	0.999	0.9864	0.9732	

전체 결과를 비교하였을 때 범위를 이상치 판별 기준으로 하여 분위수 0.99에 대한 threshold를 선정하였을 때가 모든 성능 지표에서 가장 우수한 결과를 보여 최종적으로 적용하였다.

## 5) 최종 모델 결과

Bottleneck이 16인 적층 컨볼루션 오토인코더로 179 epoch동안 학습한 모델로 8796개의 정상 이미지를 복원하고, 범위를 이상치 판별 기준으로 하여

분위수 0.99에 대한 threshold를 선정하여 평가 데이터에 대해 이상치 탐지를 시행하였다. 탐지한 총 22개의 이미지 중 6개는 정상 이미지, 16개는 이상치 이미지였다. 이상치로 탐지한 정상 이미지의 경우, 일부 파손되거나 노면이 고르지 않은 점자블록을 검출하였다.




그림4. 이상치로 판별한 정상 이미지(좌\_원본, 우\_복원)

이상치 이미지에서는 비교적 파손 정도가 심한 경우를 검출하였다. 또한 점자블록 위의 낙엽이나 과자 봉지 등 시각장애인의 보행에 위험이 될 수 있는 이물질도 함께 탐지한 것을 볼 수 있다.

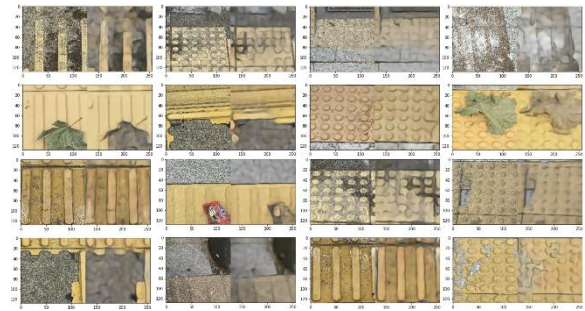


그림5. 이상치로 판별한 이상치 이미지(좌\_원본, 우\_복원)

구성한 모델의 분류 결과를 confusion matrix와 성능 평가 지표를 활용해 최종 분석하였다.

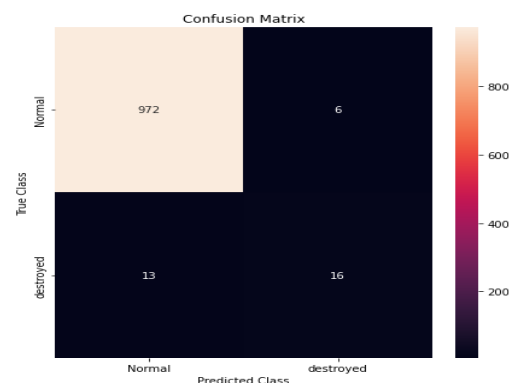


그림6. Confusion matrix

표5. 최종 분류 모델의 성능 평가 지표

F1 Score	Precision	Recall	AUC
0.9903	0.9868	0.9939	0.9402



이상 점자블록의 경우 데이터 수집이 어려워 불균형 데이터셋을 형성하였지만, 이상치로 분류된 이미지 중 파손정도가 심하거나 이물질이 있는 점자블록을 잘 탐지하였고, 전체적으로 높은 정밀도와 재현율을 가져 분류기로서 우수한 성능을 가짐을 확인할 수 있다.

## 6) 라즈베리 파이 연동

라즈베리 파이를 통해 실시간으로 영상을 모델에 입력 받아 결과값을 도출하는 임베디드 시스템을 구현하였다. AI모델을 모바일 디바이스에서 활용할 수 있게 경량화된 TensorFlow lite를 활용하였으며, 학습한 모델을 tflite 형식으로 변환시켜 적용하였다.

먼저 무선 네트워크를 통해 노트북과 라즈베리 파이를 원격 연결하여 파이썬 코드를 실행한다. 코드에서는 OpenCV를 통해 실시간 영상을 불러와 모델 입력 사이즈에 맞게 resize 및 crop을 거치고, 학습된 모델을 통해 재구성된 이미지를 생성한다. 재구성 이미지와 원본 이미지 차이의 범위를 학습 데이터셋의 threshold와 비교하여 범위가 threshold보다 클 경우 warning을 출력하고, GPIO를 활용하여 부저 센서가 울리도록 시스템을 구현하였다. 하드웨어는 라즈베리 파이와 전원 공급을 위한 배터리, 영상 인식을 위한 usb카메라, 부저를 활용하여 구성하였다.




그림7.하드웨어 시스템 구성




그림8. 라즈베리 파이를 이용한 실제상황 테스트

정상 보도블록의 경우 설정한 threshold보다 현저하게 낮은 범위값을 반환하고, 부저가 울리지 않는다. 이상 보도블록의 경우 threshold보다 높은 범위값을 반환하고, warning을 출력하며 부저에 전원이 공급되어 소리가 울리는 것을 확인할 수 있다. 정상

과 이상치의 범위 값이 뚜렷하게 차이 나고, 실시간으로 테스트하였을 때도 적절한 결과값을 반환하여 작동하였기 때문에 실제 상황에서 활용할 수 있음을 확인하였다.

## 3. 결 론

본 연구에서는 다양한 점자블록 이미지 데이터를 수집하여 직접 구축한 모델을 통해 이상 점자블록을 검출하였다. 그 후, 라즈베리 파이를 이용해 실시간 환경에서 탐지를 시행하여 소리로 위험을 경고하는 임베디드 시스템을 개발하였다. 이를 통해 이상 점자블록으로 인해 시각장애인의 보행에 위험이 될 수 있는 상황을 사전에 방지할 수 있다.

본 연구에서는 점자블록의 환경에 대해서 이상치를 검출하였기 때문에 Canny Edge를 활용한 점자블록 인식 연구[5]와 연동하여 시스템을 구축하면 더 좋은 활용도를 보일 수 있을 것이다. 추가로, 이상 점자블록 탐지 시 해당 위치와 이미지를 수집하여 동일 위치에서 일정 기준 이상의 탐지 빈도를 보인 경우 이를 관할 기관에 전송하여 즉각적인 조치가 이루어질 수 있도록 연계하여 발전시킨다면, 높은 수준의 시각 장애인의 보행 안전성을 확보할 수 있을 것으로 기대한다.

## 참고 문헌

- [1] 방치되는 시민의 눈, 무용지물 점자블록, <http://news.cauon.net/news/articleView.html?idxno=35737>
- [2] 파손된 점자블록, 안전사고로...3년간 민원1.7배 급증, <https://www.socialfocus.co.kr/news/articleView.html?idxno=10201>
- [3] T. Luo and S. G. Nagarajan, "Distributed anomaly detection using autoencoder neural networks in wsn for iot", IEEE International Conference on Communications (ICC), 2018.
- [4] Gun-Ha Kang, Jung-Mo Sohn, Gun-Wu Sim, "Comparative Analysis of Anomaly Detection Models

using AE and  
Suggestion of Criteria for Determining Outliers”,  
Journal of The Korea Society of Computer and  
Information, 2021

[5] 오수진, “인공 신경망을 이용한 점자블록인식 방  
안”(석사, 한양대학교 공학대학원, 서울, 2017),